Стохастическое моделирование

МОДЕЛИРОВАНИЕ НЕПРЕРЫВНЫХ СЛУЧАЙНЫХ ВЕЛИЧИН

Случайные объекты и базовый датчик

1. Случайные события
2. Случайные величины
3. Случайные процессы
4. Случайные потоки событий

Непрерывные случайные величины (НепрСВ)

Пусть ξ – непрерывная случайная величина.
Она может быть задана:

$F_\xi(x) = \mathrm{P}\{\xi < x\}$ – функцией распределения

$p_\xi(x) = F_\xi'(x)$ – плотностью вероятностей

$$F_\xi(x) = \int_{-\infty}^{x} p_\xi(u)du$$

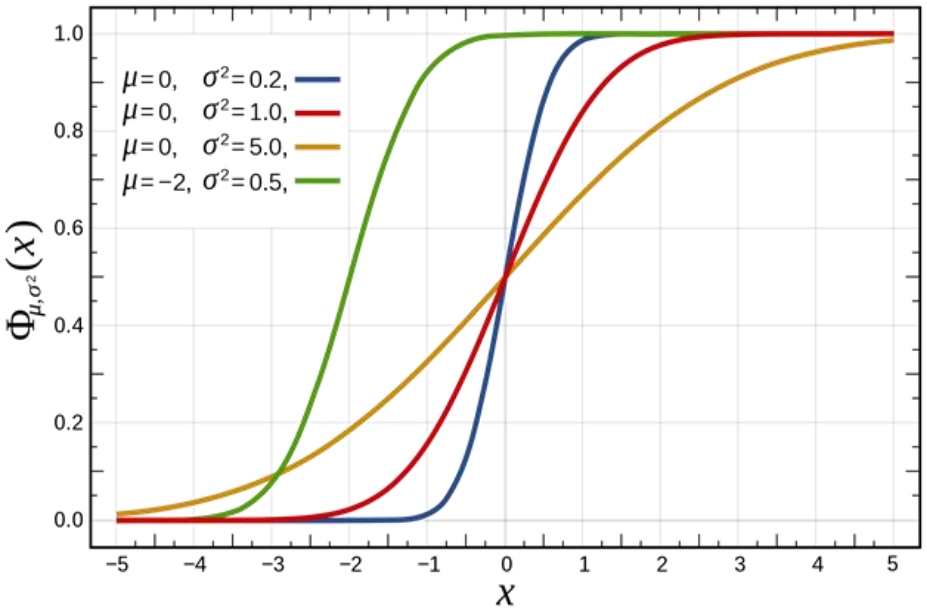

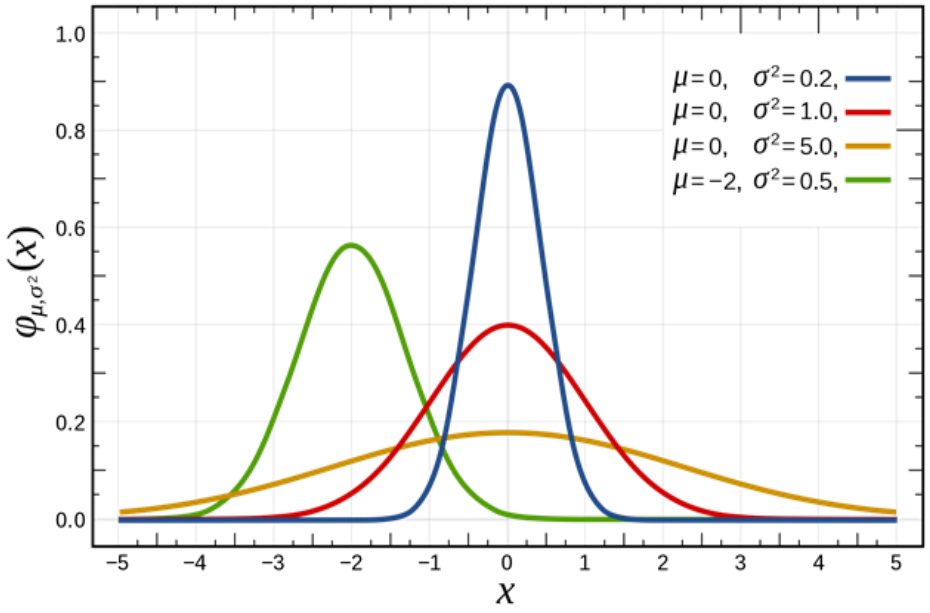

Равномерное распределение

$\xi \in [a;b]$

$$p_\xi(x) = \begin{cases} \dfrac{1}{b-a}, \text{ if } a \le x \le b \\ 0, \text{ if } \ x < a \text{ or } x > b \end{cases}$$

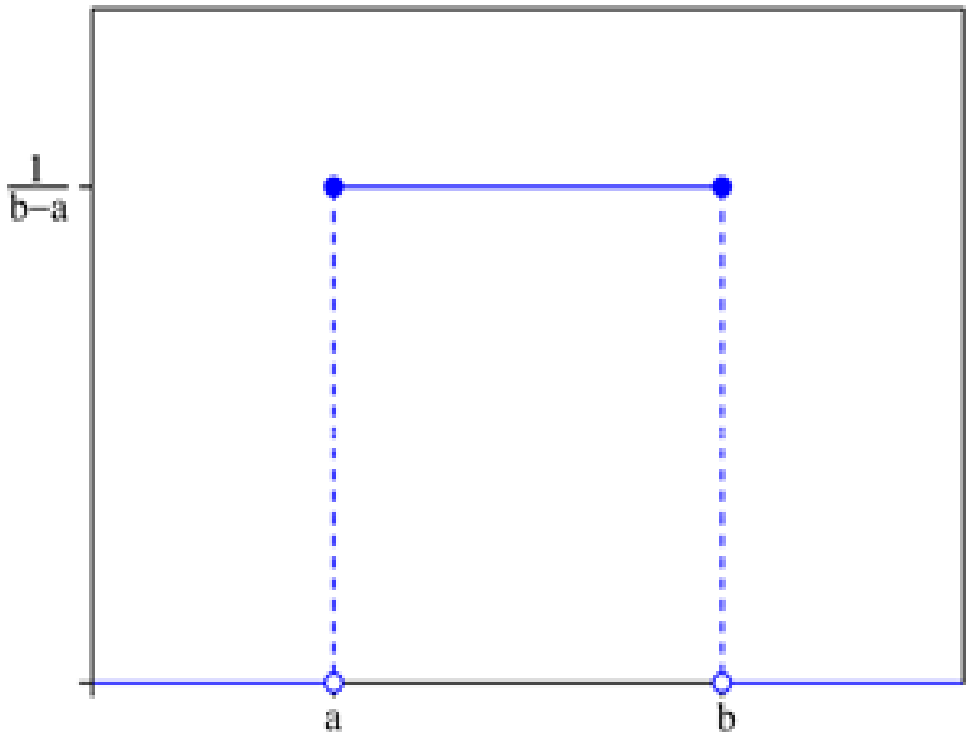

ДАТЧИК: $\xi = a + (b-a)\cdot\alpha$

Метод обратной функции

Пусть $\xi = \varphi(\alpha)$

$\alpha = \varphi^{-1}(x)$

Допустим, что $\varphi(\cdot) \uparrow$

$$F_\xi(x) = \mathrm{P}\{\xi < x\} = \mathrm{P}\{\varphi(\alpha) < x\} = \mathrm{P}\{\alpha < \varphi^{-1}(x)\} = \varphi^{-1}(x)$$

$$\varphi(x) = F_\xi^{-1}(x)$$

$$\xi = F_\xi^{-1}(\alpha) \qquad \xi = F_\xi^{-1}(1-\alpha)$$

Экспоненциальное (показательное) распределение

Это распределение вероятностей
длины интервала времени между двумя последовательными моментами наступления однородных независимых событий, которые наступают с интенсивностью λ (событий за интервал)

$$\xi \geq 0$$

$$F_\xi(x) = 1 - e^{-\lambda x} \qquad p_\xi(x) = \lambda e^{-\lambda x}$$

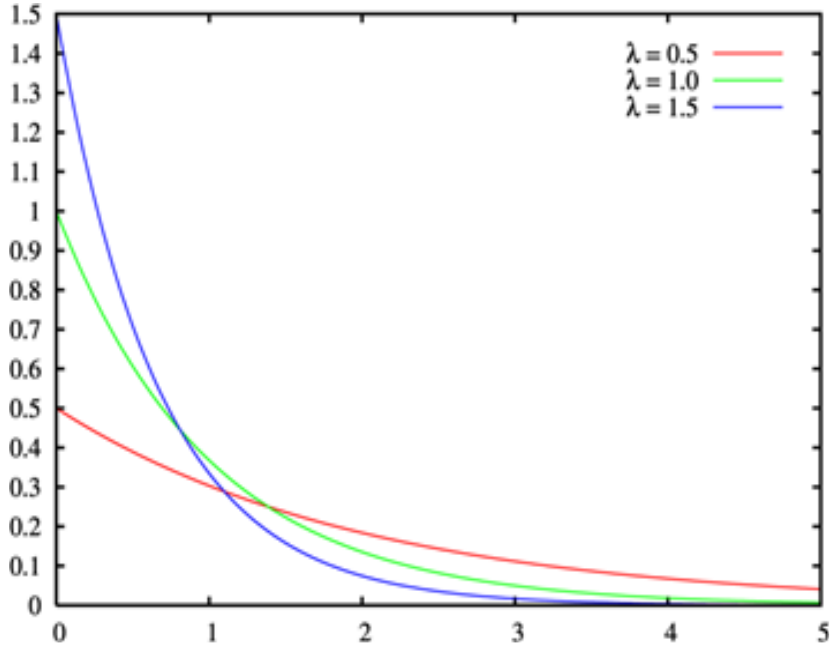

ДАТЧИК:

$$\xi = -\frac{\ln(1-\alpha)}{\lambda} \Leftrightarrow \xi = -\frac{\ln \alpha}{\lambda}$$

НепрСВ, заданная гистограммой

Обычно **получается в результате экспериментов**

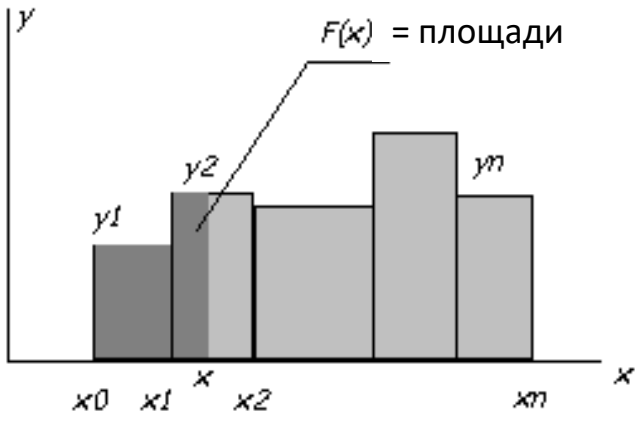

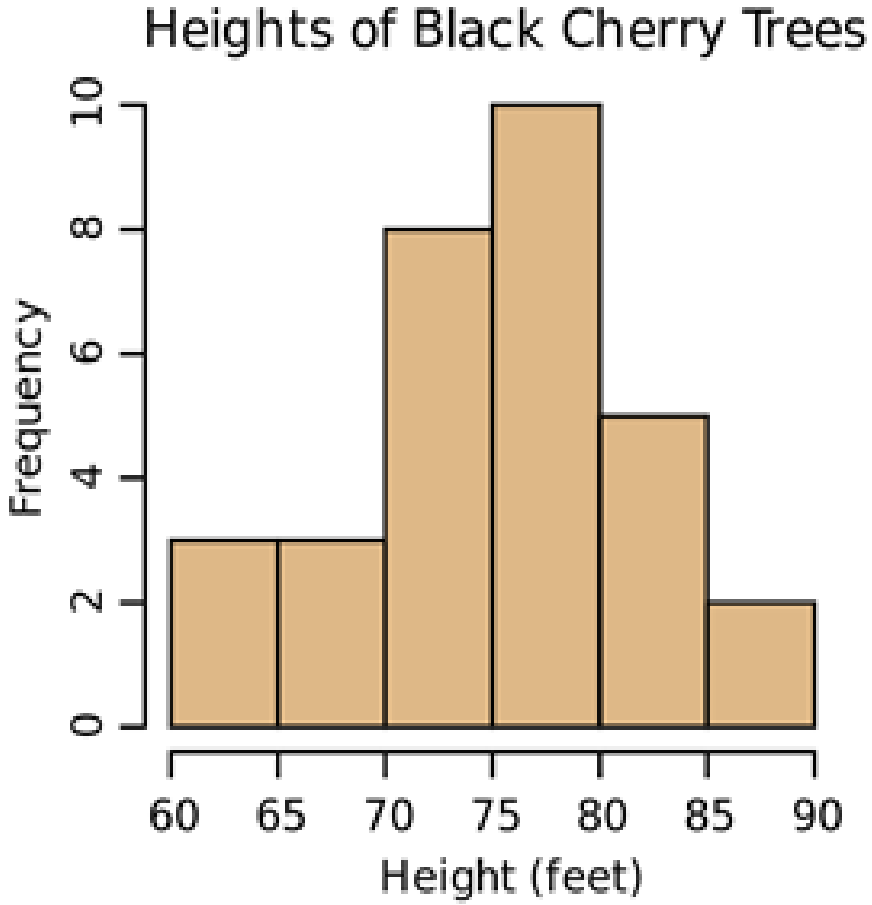

Общая площадь: $\sum_{k=1}^{n} y_k (x_k - x_{k-1}) = 1$

НепрСВ, заданная гистограммой

$$F(x) = \begin{cases} y_1(x - x_0), \ \ x_0 \le x \le x_1 \\ y_1(x_1 - x_0) + y_2(x - x_1), \ \ x_1 \le x \le x_2 \\ \ldots\ldots \end{cases}$$

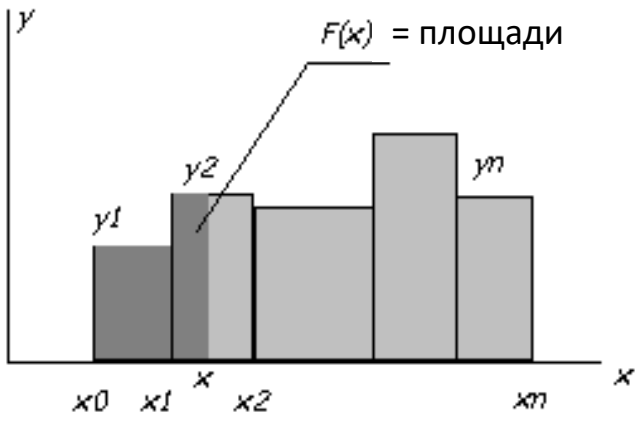

$$F(x) = \sum_{s=1}^{k-1} y_s(x_s - x_{s-1}) + y_k(x - x_k), \ \ where \ \ k: \ x_{k-1} \le x \le x_k$$

Алгоритм: $\alpha - y_1(x_1 - x_0) - y_2(x_2 - x_1) - \ldots - y_k(x_k - x_{k-1}) = M < 0$

$$\xi = x_k + \frac{M}{y_k}$$

НепрСВ, заданная гистограммой

Алгоритм:

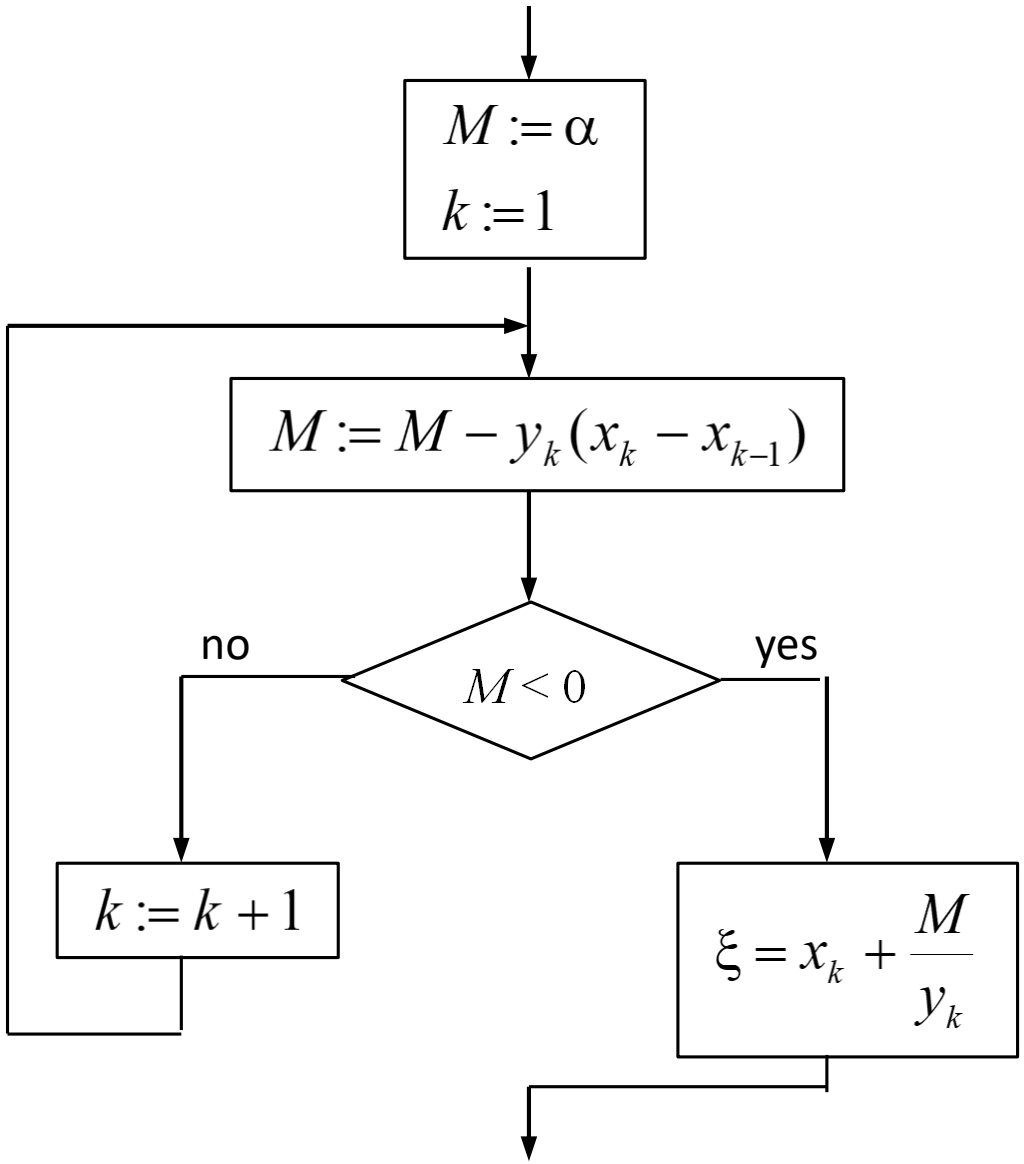

Метод суперпозиции

Применяется для случая, когда $p_\xi(x) = \sum_{i=1}^{n} \pi_i \cdot p_i(x)$ $\quad \pi_i \geq 0 \quad \sum_{i=1}^{n} \pi_i = 1 \quad p_i(x) \geq 0 \quad \int_{-\infty}^{+\infty} p_i(x)dx = 1$

Алгоритм:

1. Генерируем ДСВ β с рядом распределения $\mathrm{P}\{\beta = i\} = \pi_i, \; i = 1, 2, \ldots, n$
2. Генерируем НепрСВ ξ с плотностью $p_\beta(x)$

Гиперэкспоненциальное распределение

моделирует смесь экспоненциальных СВ

часто используется для аппроксимации более сложных в исследовании СВ

$$p_\xi(x) = \sum_{i=1}^{n} \pi_i \cdot \lambda_i e^{-\lambda_i x}$$

Алгоритм:

1. Генерируем ДСВ i с рядом распределения π_i , i = 1, 2, …, n
2. Генерируем экспоненциальную СВ ξ с параметром λ_i : $\xi = -\dfrac{\ln \alpha}{\lambda_i}$

Метод исключения

Запишем плотность вероятностей СВ в виде $p_\xi(x) = \frac{1}{G} g(x)$

$$g(x) \geq 0 \qquad \int_{-\infty}^{+\infty} g(x)dx = G < +\infty$$

Теорема. Если двумерная СВ (ξ, η) имеет плотность распределения

$$p_{\xi\eta}(x, y) = \begin{cases} \frac{1}{G}, \ if \ \ (x, y) \in G \\ 0, \ if \ \ (x, y) \notin G \end{cases}$$

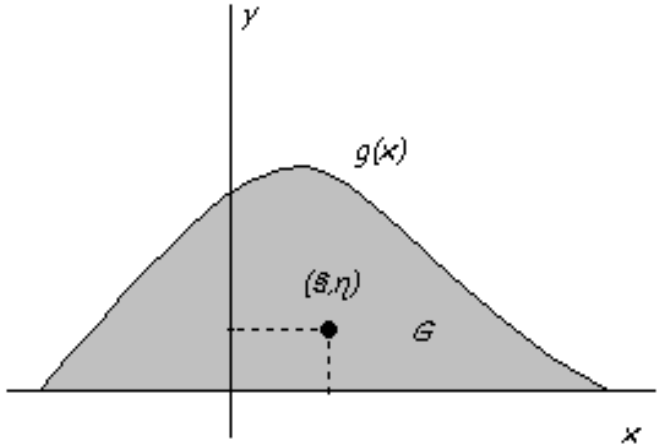

тогда СВ ξ имеет плотность $p_\xi(x) = \frac{1}{G} g(x)$

Метод исключения

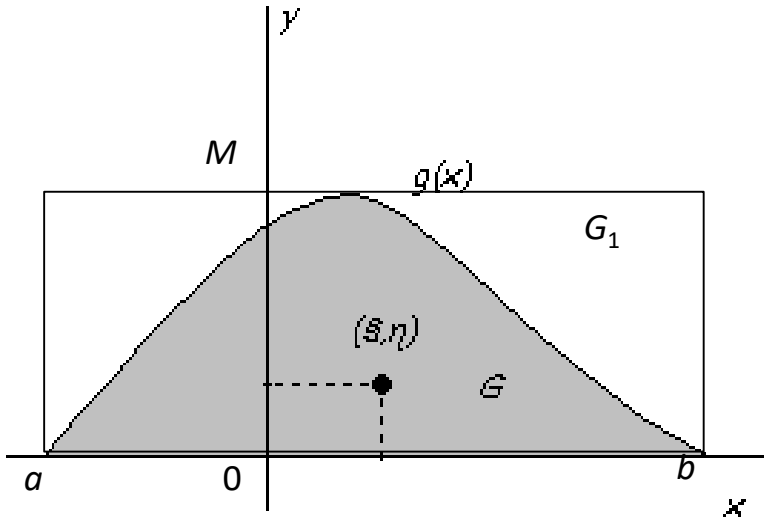

Например, пусть $a \le \xi \le b$ и $\max\limits_{x} p_{\xi}(x) = M$

$$G_1 = [a,b][0,M]$$

Алгоритм:

1. Генерируем две независимых равномерно распределенных СВ:

$$\xi = a + \alpha_1 (b - a),$$

$$\eta = \alpha_2 M .$$

2. Если $\eta \le p_{\xi}(\xi)$, тогда ξ есть результат моделирования, иначе переходим на шаг 1.

Непрерывные случайные величины

СПЕЦИАЛЬНЫЕ МЕТОДЫ МОДЕЛИРОВАНИЯ

Нормальное (гауссовское) распределение

нормальные случайные величины (НСВ) обычно используются для моделирования **величин, значения которых распределены в окрестности заданной точки (среднего)**

$$\xi = N(a, \sigma^2)$$

- a – математическое ожидание (среднее)
- σ – среднеквадратическое (стандартное) отклонение
- σ^2 – дисперсия

$$p_\xi(x) = \frac{1}{\sigma\sqrt{2\pi}} \cdot e^{-\frac{(x-a)^2}{2\sigma^2}}$$

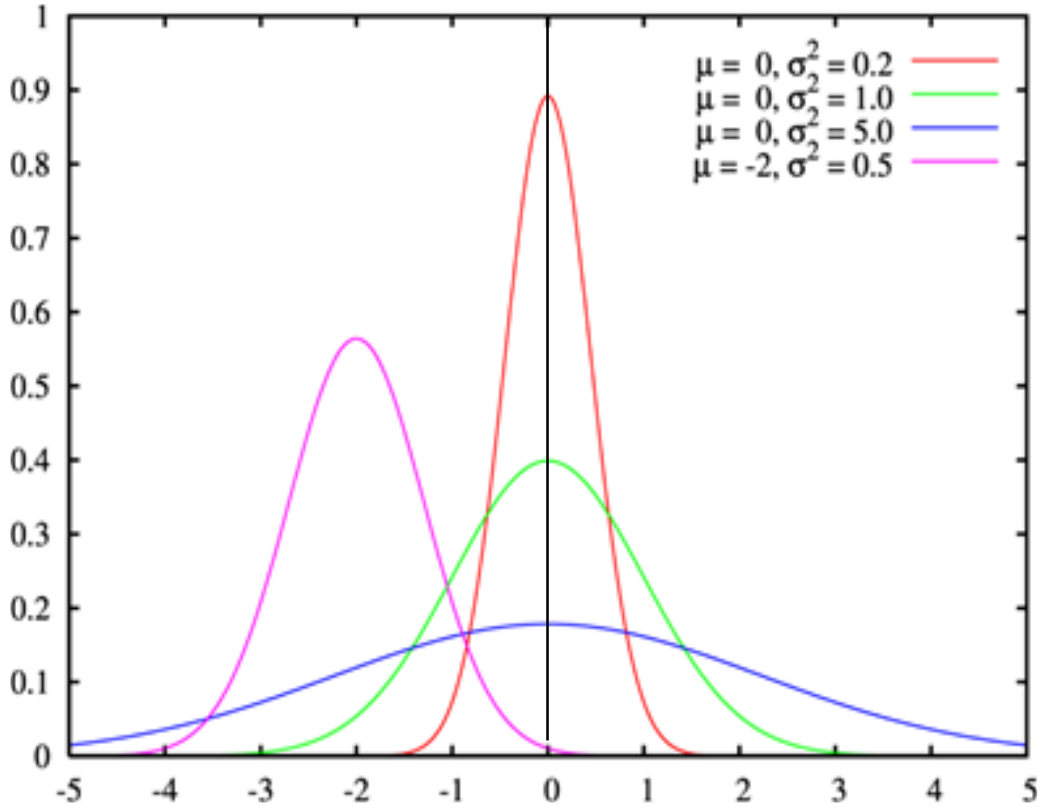

Нормальное распределение

КАК МОДЕЛИРОВАТЬ?

Стандартная нормальная случайная величина (СНСВ): $\zeta = N(0,1)$

$$p_\zeta(x) = \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{x^2}{2}}$$

НСВ $N(a, \sigma^2)$: $\xi = \sigma \cdot \zeta + a$

Стандартная нормальная случайная величина

1-2. **ДАТЧИКИ**, ОСНОВАННЫЕ НА ЦЕНТРАЛЬНОЙ ПРЕДЕЛЬНОЙ ТЕОРЕМЕ (МЕТОД СУММИРОВАНИЯ)

Идея: пусть $\eta_1, \eta_2, \ldots, \eta_n : M\{\eta_i\} = a, D\{\eta_i\} = \sigma^2$ есть некоторые одинаково распределенные СВ

тогда $\zeta_n = \dfrac{\eta_1 + \eta_2 + \ldots + \eta_n - n \cdot a}{\sigma\sqrt{n}} \underset{n\to\infty}{\overset{on\ distr.}{\to}} N(0,1)$

Пусть $\eta_i = \alpha_i \quad M\{\alpha_i\} = \dfrac{1}{2} \quad D\{\alpha_i\} = \dfrac{1}{12}$

тогда $\zeta = \sqrt{\dfrac{12}{n}}\left(\sum_{i=1}^{n} \alpha_i - \dfrac{n}{2}\right)$

ДАТЧИКИ:

1. $n = 12$: $\zeta = \sum_{i=1}^{12} \alpha_i - 6$
2. $\zeta^* = \zeta + \dfrac{1}{240}\left(\zeta^3 - 3\zeta\right)$

Стандартная нормальная случайная величина

3. **ДАТЧИК** НА ОСНОВЕ ПРЕОБРАЗОВАНИЯ БОКСА-МЮЛЛЕРА

$$\zeta_1 = \sqrt{-2\ln\alpha_1}\cos\left(2\pi\alpha_2\right) \qquad \zeta_2 = \sqrt{-2\ln\alpha_1}\sin\left(2\pi\alpha_2\right)$$

Статистическая обработка результатов для НепрСВ

1. В результате моделирования НепрСВ, получаем выборку значений из непрерывного диапазона:

2.234, 0.167, 3.1, 3.47, 1.104, -0.345, -1.241, 2.133, -1.02, -0.546, 2.654, 1.13, -1.987, -2.02, 1.55, 3.14

2. Готовим сетку интервалов:

a) (-5; -4] (-4; -3] (-3; -2] (-2; -1] (-1; 0] (0; 1] (1; 2] (2; 3] (3; 4] (4; 5]

b) min = -2.02; max = 3.47

-> (-3; -2] (-2; -1] (-1; 0] (0; 1] (1; 2] (2; 3] (3; 4]

-> (max-min) = 5.49

-> например, если хотим *k* = 5 интервалов: (max-min)/5 = 5.49/5 = 1,098

-> [-2.02; -1.471] (-0.922; 0.176] (0.176; 1.274] (1.274; 2.372] (2.372; 3.47]

(на практике берут общую ширину 5.49+0.01 вместо 5.49, чтобы слегка расширить границы

-> выбрать *k*, используя специальные методы

Специальные методы выбора числа интервалов

Square-root choice [edit]

$$k = \lceil \sqrt{n} \rceil$$

which takes the square root of the number of data points in the sample (used by Excel histograms and many others) and rounds to the next integer.[14]

Sturges' formula [edit]

Sturges' formula[12] is derived from a binomial distribution and implicitly assumes an approximately normal distribution.

$$k = \lceil \log_2 n \rceil + 1,$$

It implicitly bases the bin sizes on the range of the data and can perform poorly if $n < 30$, because the number of bins will be small—less than seven—and unlikely to show trends in the data well. It may also perform poorly if the data are not normally distributed.

Rice Rule [edit]

$$k = \lceil 2n^{1/3} \rceil,$$

The Rice Rule [15] is presented as a simple alternative to Sturges's rule.

Doane's formula [edit]

Doane's formula[16] is a modification of Sturges' formula which attempts to improve its performance with non-normal data.

$$k = 1 + \log_2(n) + \log_2\left(1 + \frac{|g_1|}{\sigma_{g_1}}\right)$$

where g_1 is the estimated 3rd-moment-skewness of the distribution and

$$\sigma_{g_1} = \sqrt{\frac{6(n-2)}{(n+1)(n+3)}}$$

Scott's normal reference rule [edit]

$$h = \frac{3.5\hat{\sigma}}{n^{1/3}},$$

where $\hat{\sigma}$ is the sample standard deviation. Scott's normal reference rule[17] is optimal for random samples of normally distributed data, in the sense that it minimizes the integrated mean squared error of the density estimate.[11]

Специальные методы выбора числа интервалов

Freedman–Diaconis' choice [edit]

The Freedman–Diaconis rule is:[18][11]

$$h = 2\frac{\mathrm{IQR}(x)}{n^{1/3}},$$

which is based on the interquartile range, denoted by IQR. It replaces 3.5σ of Scott's rule with 2 IQR, which is less sensitive than the standard deviation to outliers in data.

Minimizing cross-validation estimated squared error [edit]

This approach of minimizing integrated mean squared error from Scott's rule can be generalized beyond normal distributions, by using leave-one out cross validation:[19][20]

$$\arg\min_h \hat{J}(h) = \arg\min_h \left(\frac{2}{(n-1)h} - \frac{n+1}{n^2(n-1)h} \sum_k N_k^2 \right)$$

Here, N_k is the number of datapoints in the *k*th bin, and choosing the value of *h* that minimizes *J* will minimize integrated mean squared error.

Shimazaki and Shinomoto's choice [edit]

The choice is based on minimization of an estimated L^2 risk function[21]

$$\arg\min_h \frac{2\bar{m} - v}{h^2}$$

where $\bar{m}$ and v are mean and biased variance of a histogram with bin-width h, $\bar{m} = \frac{1}{k}\sum_{i=1}^{k} m_i$ and $v = \frac{1}{k}\sum_{i=1}^{k}(m_i - \bar{m})^2$.

Variable bin widths [edit]

Rather than choosing evenly spaced bins, for some applications it is preferable to vary the bin width. This avoids bins with low counts. A common case is to choose *equiprobable bins*, where the number of samples in each bin is expected to be approximately equal. The bins may be chosen according to some known distribution or may be chosen based on the data so that each bin has $\approx n/k$ samples. When plotting the histogram, the *frequency density* is used for the dependent axis. While all bins have approximately equal area, the heights of the histogram approximate the density distribution.

For equiprobable bins, the following rule for the number of bins is suggested:[22]

$$k = 2n^{2/5}$$

This choice of bins is motivated by maximizing the power of a Pearson chi-squared test testing whether the bins do contain

Строим гистограмму

3. Подсчитываем, сколько раз значения из выборки попали в какой-то интервал. Записываем результат в таблицу:

Интервал	(-3; -2]	(-2; -1]	(-1; 0]	(0; 1]	(1; 2]	(2; 3]	(3; 4]
Частота	1	3	2	1	3	3	3

4. Делим частоты на объем выборки (общее число значений в ней). Преобразовываем таблицу:

Интервал	(-3; -2]	(-2; -1]	(-1; 0]	(0; 1]	(1; 2]	(2; 3]	(3; 4]
Относительная частота	0.0625	0.1875	0.125	0.0625	0.1875	0.1875	0.1875

Гистограмма

Интервал	(-3; -2]	(-2; -1]	(-1; 0]	(0; 1]	(1; 2]	(2; 3]	(3; 4]
Относительная частота	0.0625	0.1875	0.125	0.0625	0.1875	0.1875	0.1875

5. Рисуем гистограмму:

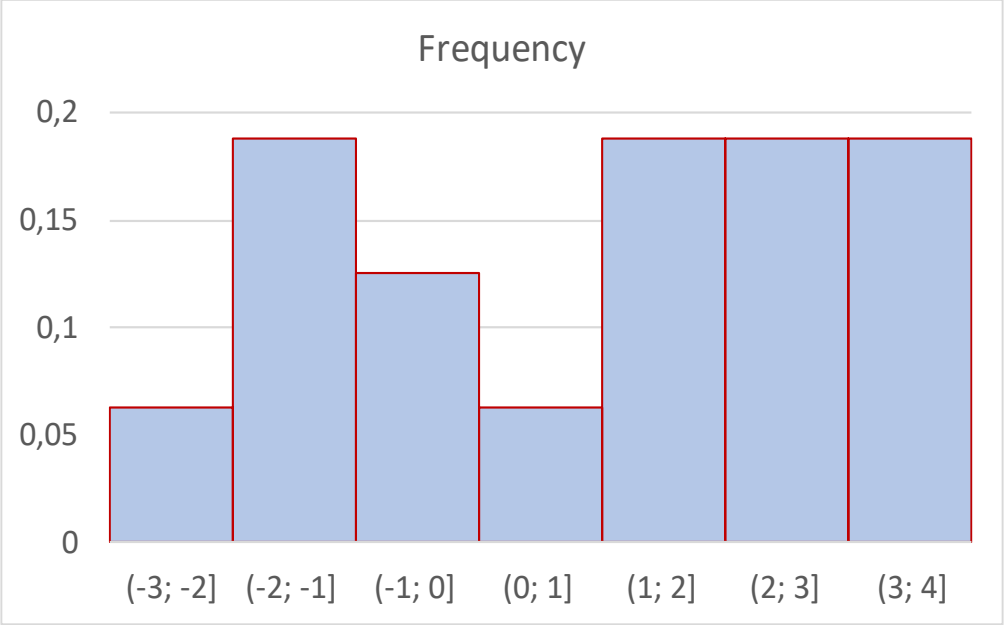

Статистическая обработка результатов для НепрСВ

Критерий хи-квадрат $\hat{X}_N^2 = \sum_{i=1}^{m} \frac{n_i^2}{Np_i} - N$

$$p_i = F_\xi(b_i) - F_\xi(a_i) = \int_{a_i}^{b_i} p_\xi(x)\,dx$$

$$p_i \approx (b_i - a_i)\, p_\xi\left(\frac{a_i + b_i}{2}\right)$$

Эмпирические среднее и дисперсия

$$\hat{\mathrm{E}}\, x = \frac{1}{N}\sum_{i=1}^{N} x_i \qquad \hat{\mathrm{D}}\, x = \frac{1}{N}\sum_{i=1}^{N} x_i^2 - (\hat{\mathrm{E}}\, x)^2$$

Лабораторная 6.2

ЗАДАНИЕ: Выполнить моделирование нормальной случайной величины любым методом. Провести статистическую обработку результатов:

a) построить гистограмму;

b) оценить точность (относительные погрешности, критерий хи-квадрат) для объемов выборки 10, 100, 1000, 10000;

c) сделать вывод.

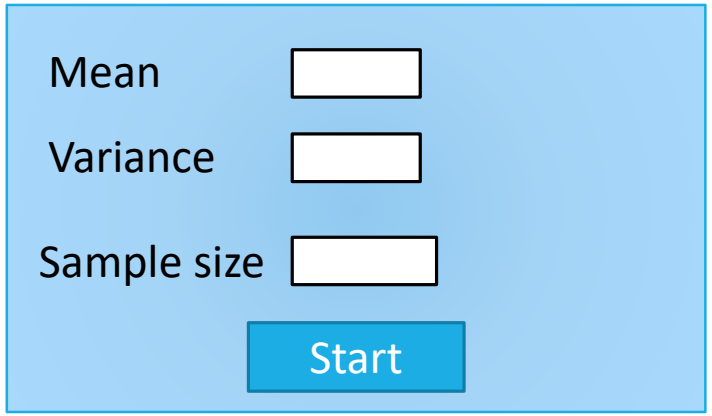

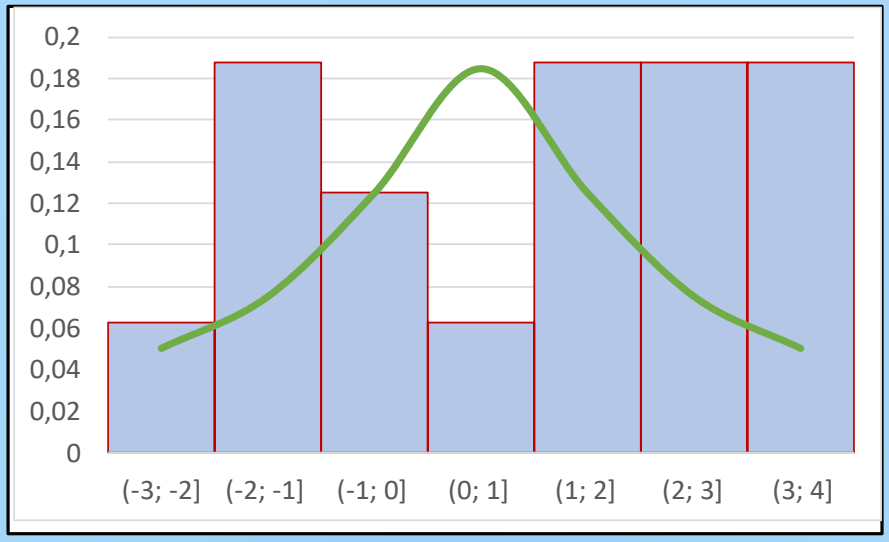

Average: 2.897 (error = 8%)

Variance: 2.072 (error = 9%)

Chi-squared: 13.51 > 11.07 is true

Гамма-распределение

- широко используется в прикладных задачах
- позволяет моделировать и аппроксимировать разные распределения
- позволяет легко оценивать и настраивать параметры распределения

$$\xi_{k,\theta},\ \xi_{\alpha,\beta} \geq 0$$

$$p_{\xi_{k,\theta}}(x) = \frac{x^{k-1}}{\theta^k \Gamma(k)} e^{-\frac{x}{\theta}} \qquad p_{\xi_{\alpha,\beta}}(x) = \frac{\beta^\alpha x^{\alpha-1}}{\Gamma(\alpha)} e^{-\beta x}$$

$$\Gamma(z) = \int_0^\infty t^{z-1} e^{-t} dt \qquad \Gamma(n) = (n-1)!,\ \Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$$

- k или α – параметр формы
- θ или β – параметр масштаба

$$k, \theta, \alpha, \beta > 0$$

$$\mathrm{E}\{\xi_{\alpha,\beta}\} = \frac{\alpha}{\beta},\ \mathrm{Var}\{\xi_{\alpha,\beta}\} = \frac{\alpha}{\beta^2}$$

Гамма-распределение

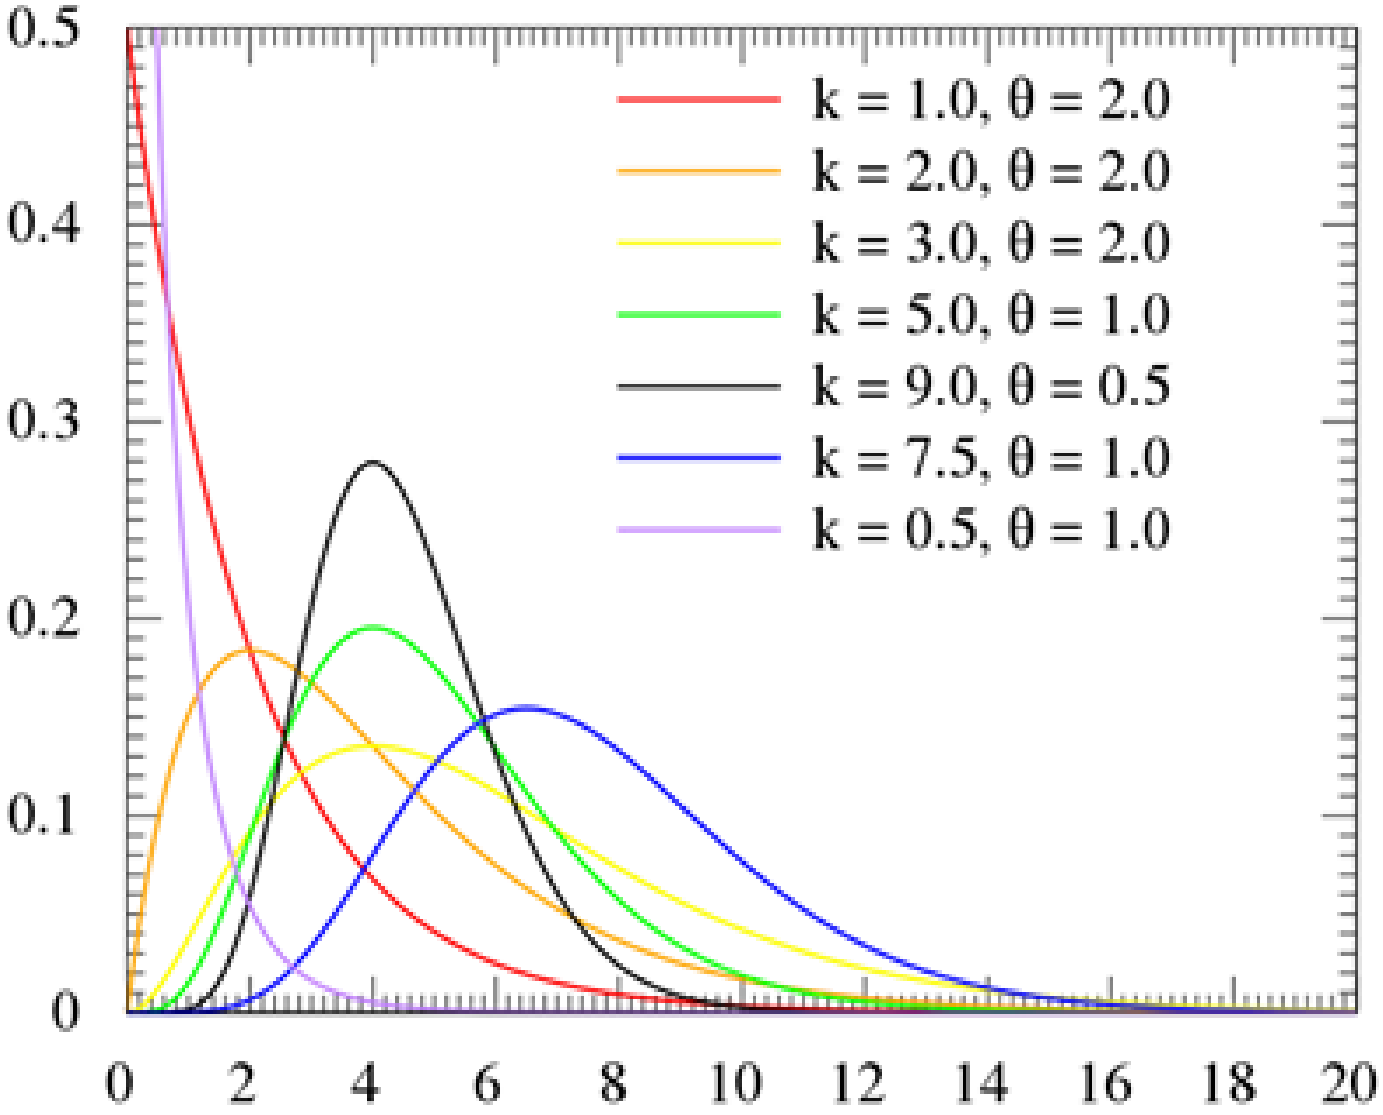

Гамма-распределение с одним параметром

Параметр масштаба = 1

$$p_{\zeta_\alpha}(x) = \frac{x^{\alpha-1}}{\Gamma(\alpha)} e^{-x} \qquad \xi_{\alpha,\beta} = \frac{\zeta_\alpha}{\beta}$$

Свойства:

$$\zeta_\alpha + \zeta_\rho = \zeta_{\alpha+\rho}$$

если α – целое, то $\zeta_\alpha = \sum_{i=1}^{\alpha} \zeta_1$

если α = 1, то распределение является экспоненциальным с параметром λ = 1

Алгоритм моделирования СВ, имеющей гамма-распределение

1. $d := \mathrm{Int}(\alpha),\ \delta := \alpha - d$
2. Если $\delta > 0$, то генерируем ζ_δ
3. Если $d > 0$, то генерируем d экспоненциальных RV с параметром $\lambda = 1$
4. Суммируем все полученные значения и делим результат на β

Моделирование СВ, имеющей гамма-распределение с одним параметром

Задача: получить реализацию ζ_δ, где $\delta \in (0;1)$

1. $r := \dfrac{e}{e+\delta}$

2. Генерируем две базовые СВ: α_1, α_2

3. Если $\alpha_1 \le r$, то $\eta_1 := \left(\dfrac{\alpha_1}{r}\right)^{\frac{1}{\delta}}$, $\eta_2 := \alpha_2 \cdot \eta_1^{\delta-1}$

   иначе $\eta_1 := 1 - \ln\dfrac{\alpha_1 - r}{1-r}$, $\eta_2 := \alpha_2 \cdot e^{-\eta_1}$

4. Если $\eta_2 > \eta_1^{\delta-1} \cdot e^{-\eta_1}$, то переход на шаг 2

   иначе берем η_1 в качестве результата моделирования